

ТЕХНИЧЕСКОЕ ЗАДАНИЕ

1. Цель и контекст

Создать MVP веб-платформы MedServicePrice.kz — агрегатора цен на медицинские услуги (анализы, приёмы врачей, диагностику) в Казахстане. Платформа автоматически собирает актуальные прайсы с открытых источников в интернете, структурирует их и предоставляет пользователю удобный интерфейс для сравнения цен и выбора наиболее выгодного предложения — по аналогии с сервисом Aviasales, но для медицины.

Проблема: пациент вынужден обходить десятки сайтов клиник вручную, чтобы сравнить стоимость анализа крови, приёма терапевта или УЗИ. Рынок непрозрачен, цены нигде не агрегированы.

2. Источники данных

2.1 Целевые источники для парсинга

Участники самостоятельно определяют финальный перечень источников исходя из доступности. Ниже приведён ориентировочный список:

Источник	Тип данных	Формат
kdl.kz / kdlolymp.kz	Лаборатория KDL — анализы, цены, сроки	HTML-страницы, прайс-листы
doq.kz	Агрегатор клиник — приёмы врачей, стоимость	HTML/JSON API
invitro.kz	Инвитро — лабораторные исследования	HTML, PDF
helix.kz	Хеликс — анализы и диагностика	HTML
olymp.kz	Медцентр Олимп — широкий спектр услуг	HTML, PDF
medel.kz	МЕДЭЛ — многопрофильная клиника	HTML
aksai-clinic.kz	Региональные клиники	HTML
mck.kz	Медицинский центр МЦК	HTML
сайты городских и областных клиник	Государственные и частные клиники РК	HTML, PDF, DOCX
2gis.kz / Google Maps	Адреса, режим работы клиник	API / HTML

Участники вправе добавлять дополнительные источники по своему усмотрению. Приветствуется охват максимального числа городов Казахстана (Алматы, Астана, Шымкент, Актобе, Павлодар и др.).

2.2 Структура собираемых данных

Поле	Тип	Описание
clinic_id	uuid	Уникальный идентификатор клиники
clinic_name	string	Название клиники
city	string	Город
address	string	Адрес

phone	string	Телефон
working_hours	string	Режим работы
source_url	string	URL источника данных
service_id	uuid	Уникальный идентификатор услуги
service_name_raw	string	Наименование услуги как на сайте
service_name_norm	string	Нормализованное название (привязка к справочнику)
category	enum	Категория: лаборатория / приём врача / диагностика / процедура
price_kzt	decimal	Цена в тенге
currency	enum	KZT / USD (конвертировать в KZT)
duration_days	int	Срок выполнения (для анализов), дней
parsed_at	datetime	Дата и время парсинга
is_active	bool	Флаг актуальности записи

3. Функциональные требования

3.1 Модуль сбора данных (парсер)

- Автоматический обход целевых сайтов и извлечение прайс-листов
- Поддержка форматов: HTML-страницы, PDF, DOCX, Excel (если публикуются клиниками открыто)
- Дедупликация: не создавать дублирующие записи при повторном запуске
- Журналирование ошибок парсинга с указанием источника и причины
- Хранение сырых данных отдельно от нормализованных (raw-слой)
- Возможность запуска парсинга вручную через интерфейс или по расписанию (cron)

3.2 Нормализация и справочник услуг

Система должна приводить разнородные названия к единому справочнику услуг. Пример: «ОАК», «Общий анализ крови», «СВС», «Клинический анализ крови» → одна услуга «Общий анализ крови (ОАК)»

- Справочник услуг формируется командой в процессе разработки на основе анализа собранных данных
- Справочник должен содержать: id, название, синонимы, категорию
- Нормализация может выполняться вручную, алгоритмически или с помощью AI (на усмотрение команды)
- Непривязанные услуги попадают в очередь ручной разметки (unmatched queue)

3.3 Пользовательский интерфейс — поиск и сравнение

- Строка поиска услуги с автодополнением по справочнику
- Фильтры: город, категория услуги, ценовой диапазон, рейтинг клиники, наличие онлайн-записи
- Результаты: список клиник с ценой, адресом, режимом работы, ссылкой на источник
- Сортировка: по цене (возр./убыв.), по расстоянию (если геолокация разрешена), по дате обновления

- Карточка клиники: все услуги данной клиники, контакты, ссылка на сайт
- Отображение даты последнего обновления цены — прозрачность для пользователя
- Адаптивный интерфейс: корректное отображение на мобильных устройствах

3.4 Дополнительные функции (опционально, дают преимущество)

- Карта клиник с маркерами (Leaflet / Google Maps)
- Подписка на изменение цены по конкретной услуге и клинике
- Сравнение нескольких клиник в режиме «таблица»
- История изменения цен по услуге
- Интеграция с 2GIS или Google Maps для маршрута до клиники

4. Нефункциональные требования

Параметр	Требование
Актуальность данных	Данные обновляются не реже 1 раза в сутки (для MVP допустимо реже)
Время ответа UI	Поисковая выдача — не более 3 секунд
Корректность цен	Отображать дату парсинга; не выдавать данные старше 30 дней как актуальные
Масштабируемость	Архитектура должна допускать добавление новых источников без переработки ядра
Отказоустойчивость парсера	Недоступность одного источника не должна останавливать сбор с остальных
Хранение	Сырые данные хранятся не менее 90 дней для аудита

5. Технологии

Стек технологий выбирается командой самостоятельно. Ниже приведены рекомендуемые варианты:

Слой	Варианты
Парсинг	Python (Scrapy, BeautifulSoup, Playwright, Selenium), Node.js (Puppeteer)
Бэкенд / API	FastAPI, Flask, Django, Node.js (Express)
Фронтенд	React, Vue, Next.js — любой современный фреймворк
База данных	PostgreSQL, MySQL, MongoDB, SQLite (для MVP)
Очереди / расписание	Celery + Redis, cron, APScheduler
Поиск	PostgreSQL full-text search, Elasticsearch, MeiliSearch
Деплой	Docker, любой облачный провайдер

6. Результаты, которые сдаёт команда

- Рабочий MVP: репозиторий с инструкцией запуска (README)

- База данных с реальными спарсенными данными (минимум 3 источника, минимум 100 услуг)
- Справочник услуг (минимум 50 нормализованных позиций)
- Презентация решения: 5–7 слайдов (архитектура, демо, источники, план развития)
- Демо-видео (опционально, 1–3 минуты)

7. Критерии оценки

Критерий	Вес	Описание
Качество данных	25%	Актуальность, количество источников, корректность нормализации
UX / удобство поиска	25%	Скорость нахождения нужной услуги, читаемость результатов
Техническая реализация	20%	Качество кода, архитектура, обработка ошибок
Охват рынка	15%	Количество клиник и городов в базе
Дополнительные функции	15%	Карта, история цен, сравнение, подписки

8. Ограничения и правила

- Разрешён парсинг только открытых (публичных) данных без авторизации
- Запрещено создавать чрезмерную нагрузку на сайты источников (соблюдать задержки между запросами)
- Все данные в MVP являются публичными — персональные данные пациентов не собираются
- Команда несёт ответственность за соблюдение robots.txt целевых сайтов